TECNOLÓGICO NACIONAL DE MÉXICO · INSTITUTO TECNOLÓGICO DE COLIMA
Proyecto Integrador Colegiado: TRUSTED DATA LAB (Unidades 3 y 4 · Semestre Ago–Dic 2026)

Entrega E0 · Etiqueta: e0
Fecha: 09/11/2026

[E0] ARRANQUE, PROPUESTA TÉCNICA Y MÁQUINA DE CAPTURA · CITRO-DATA LAB COLIMA

Alumno / Equipo: Norberto Daniel Escareño Montaño	**No. Control:** 23460323	**Correo:** 23460323@colima.tecnm.mx
Ingeniería de Datos (CMD-2602): Mtro. Armando Román Gallardo Heredia	**Análisis Estadístico para Ciencia de Datos:** Mtro. Mónico Joel Sánchez Velasco	

Repositorio GitHub: https://github.com/NorbertoDaniel65/tdl-escareno-limon-colima
Etiqueta / Release E0: https://github.com/NorbertoDaniel65/tdl-escareno-limon-colima/releases/tag/e0 · **Ficha ENTREGA.md:** docs/E0/ENTREGA.md

1. FICHA DEL OBSERVATORIO

Nombre del Observatorio	**CITRO-DATA LAB COLIMA:** Observatorio Certificado de Inteligencia Agroclimática y Precios Mayoristas del Limón Mexicano (*Citrus aurantifolia* #5).
Sector Económico (Vertical)	Agroindustria Citrícola y Comercialización Hortofrutícola Mayorista (Cadena de Valor del Limón con Semilla #5).
Región de Estudio y Grupos Comparables	**Origen Productivo (4 Municipios de Colima):** Tecomán (`06009`), Armería (`06001`), Manzanillo (`06007`) y Colima (`06002`). **Destino Comercial (4 Mercados Nacionales):** Colima (Empacadoras Regionales), Guadalajara (Mercado de Abastos), CDMX (Central de Abasto Iztapalapa) y Monterrey (Mercado Estrella).
Pregunta Central Detonadora	*¿En qué semanas del año y hacia qué central de abasto nacional conviene a los productores y empacadoras de Colima colocar su producción de limón mexicano #5, anticipando con 1 a 3 meses de ventaja el impacto del estrés térmico e hídrico de Tecomán y Armería sobre la escalada de precios mayoristas?*
Cliente Potencial y Motivo Económico para Pagar	**Empacadoras y comercializadoras citrícolas del Valle de Tecomán y Armería**, asociaciones de productores y compradores mayoristas en Guadalajara/CDMX. Una variación de **$3.00 a $6.00 MXN/kg** en un embarque estándar de 20 toneladas representa entre **$60,000 y $120,000 MXN de diferencia por camión**. Hoy los productores venden sin visibilidad del diferencial real (*spread*) frente a las plazas nacionales ni del impacto rezagado del déficit hídrico sobre la oferta futura.

2. VALIDACIÓN DE CAMPO: ENTREVISTA CON ACTOR REAL DEL SECTOR (22 MINUTOS)

El **martes 3 de noviembre de 2026** se realizó una entrevista semiestructurada de **22 minutos** con un actor activo de la cadena citrícola en el corredor **Tecomán–Colima** (productor y encargado de comercialización de huerta y empaque de limón mexicano con semilla; se resguarda la identidad personal en cumplimiento estricto del principio de **Cero Datos Personales - LFPDPPP** del proyecto).

Pregunta 1 (Decisión crítica de negocio): *¿Cuál es la decisión más costosa que toman cada semana al cortar y vender la arpilla o caja de limón mexicano?*
Respuesta: "Decidir qué día cortar fuerte y a quién venderle: si entregar aquí en las empacadoras de Tecomán al precio del día o mandar viaje directo a Guadalajara. Muchas veces vendemos barato el martes porque nos dicen que la plaza está saturada, y para el viernes en Guadalajara el kilo ya subió cinco o seis pesos."

Pregunta 2 (Fuentes actuales e incertidumbre): *¿Cómo se enteran hoy de los precios en Guadalajara, CDMX o Monterrey y qué tan confiable es esa información?*
Respuesta: "Por llamadas de WhatsApp con comisionistas o rumores entre productores en la mañana. Casi nadie revisa las tablas del gobierno (SNIIM) porque su página es vieja y tediosa de consultar día por día, así que nos quedamos con el dato que nos dice el comprador, que siempre tira el precio hacia abajo."

Pregunta 3 (Relación entre clima en la huerta y precio futuro): *¿Qué señales del clima en Tecomán o Armería les avisan que va a escasear el limón o que va a cambiar el calibre (#5 vs. #4)?*
Respuesta: "El calor extremo de más de 35 grados combinado con semanas secas sin lluvia y mucha evaporación estresa el árbol: tira flor o el limón se queda chico y amarillea antes. Cuando pega una racha así o vientos fuertes en floración, sabemos que mes y medio o dos meses después va a faltar fruta de calidad y el precio se dispara, pero nadie lleva el conteo exacto con números."

Pregunta 4 (Diferencias microclimáticas en Colima): *¿Se comporta igual la producción y el clima en Tecomán, Armería, Manzanillo y la zona norte hacia Colima capital?*
Respuesta: "No, son microclimas distintos. Tecomán y Armería son mucho más cálidos y secos en estiaje; Manzanillo tiene más humedad costera y rachas de viento cuando entran sistemas del Pacífico; y hacia el valle de Colima la temperatura mínima baja más en invierno, lo que retrasa los cortes."

Pregunta 5 (Disposición de pago por el observatorio): *Si tuviera un tablero en línea que cada mañana le mostrara el precio oficial en las 4 plazas, el margen libre de flete y un pronóstico estadístico de precios a 4 semanas con alertas de estrés climático, ¿le serviría y pagaría una suscripción?*
Respuesta: "Totalmente. Si una alerta nos ayuda a negociar aunque sea un peso más por kilo en una sola corrida semanal de 10 toneladas, son diez mil pesos recuperados en una semana. Una suscripción mensual accesible para el empaque o la cooperativa se paga sola con un solo embarque."

Aprendizajes Clave Incorporados al Diseño Técnico: (1) Se creó la variable derivada `diferencial_vs_origen_mxn_kg` (*spread* comercial frente al precio base de Colima); (2) Se incorporaron indicadores bioclimáticos fisiológicos en el extractor de Open-Meteo: **Grados-Día de Desarrollo Citrícola (`grados_dia_citricos_gdd` , base 13°C)**, **Balance Hídrico FAO (`P - ET0`)** y **Días de Estrés Térmico (≥ 35°C)**; (3) Se descargó un horizonte de **60 meses continuos** para capturar los rezagos de 1 a 3 meses entre estrés en floración y escasez comercial.

3. LAS TRES PREGUNTAS ANALÍTICAS DEL PROYECTO (E1, E2 Y E3)

3.1 Pregunta E1 · Series de Tiempo y Pronóstico (Unidad 3 de Análisis Estadístico e Ing. de Datos)

- **Pregunta analítica medible:** *¿Cuál es la trayectoria esperada del precio mayorista frecuente del limón mexicano (`precio_frecuente_mxn_kg`, en MXN/kg) para los próximos 3 periodos mensuales (con intervalos de predicción al 95%), cómo se descompone su estacionalidad invernal-primaveral (picos de febrero–abril vs. valles de julio–septiembre) y cuál es la correlación cruzada con el déficit hídrico acumulado (`P - ET0`) rezagado en Tecomán?*
- **Serie histórica base:** 60 meses continuos (`2021-01` a `2025-12`, superando los 36 periodos mínimos exigidos).
- **Protocolo de modelado y validación:** Descomposición aditiva vs. multiplicativa, prueba de estacionariedad **Dickey-Fuller Aumentada (ADF)**, análisis de correlogramas **ACF y PACF**, y comparación *out-of-sample* de cuatro modelos: **Suavizamiento Exponencial Simple (SES)**, **Holt**, **Holt-Winters Estacional** y **ARIMA/SARIMA** (seleccionado por AIC). Selección del modelo ganador vía **MAE, RMSE y MAPE** y verificación de residuos con la prueba de **Ljung-Box**.

3.2 Pregunta E2 · Diseño de Experimentos Factorial 2^3 y ANOVA de Dos Vías (Unidad 4)

- **Pregunta analítica medible (Ruta Ingeniería sobre el Pipeline del Observatorio):** *¿Qué combinación de factores de ingeniería del pipeline de captura y validación (Factor A: Estrategia de consulta HTTP secuencial vs. concurrente por dominio; Factor B: Motor de validación de esquemas `pandas` nativo vs. `Pandera` vectorizado; Factor C: Formato de persistencia `CSV UTF-8` vs. `Apache Parquet Snappy`) minimiza significativamente el tiempo de ejecución (ms) y el tamaño en almacenamiento sin incrementar la tasa de error?*
- **Diseño experimental:** (1) Diseño factorial completo **2^3 con r = 3 réplicas aleatorizadas** (24 corridas sobre copias locales en Capa Bronce, sin saturar servidores externos); (2) **ANOVA de dos vías con interacción** extendiendo el formato de almacenamiento a 3 niveles (`CSV`, `Parquet Snappy`, `Parquet ZSTD`); y (3) Comparativa de matrices **2^4 completo vs. 2^{4-1} fraccionado** (estructura de alias y ahorro de corridas) más corrida de confirmación en el tratamiento óptimo.

3.3 Pregunta E3 · Análisis Multivariado: PCA y MANOVA (Unidad 5)

- **Pregunta analítica medible:** *¿Existen diferencias multivariadas estadísticamente significativas ($\alpha = 0.05$) en el vector conjunto de condiciones bioclimáticas y desempeño comercial entre los **4 municipios citrícolas de Colima** (`Tecomán`, `Armería`, `Manzanillo` y `Colima`, $g = 4$ grupos) y entre las **4 centrales mayoristas nacionales** (`Colima`, `Guadalajara`, `CDMX` y `Monterrey`), y qué Componentes Principales sintetizan el perfil de aridez térmica y rentabilidad comercial?*
- **Vector de variables numéricas (≥ 8 variables continuas simultáneas):** `temp_max_promedio_c`, `temp_min_promedio_c`, `precipitacion_acum_mm`, `evapotranspiracion_acum_mm`, `deficit_hidrico_acum_mm`, `gdd_acumulado_mes`, `viento_max_extremo_kmh`, `radiacion_media_mj_m2`, `precio_frecuente_mxn_kg` y `diferencial_vs_origen_mxn_kg`.
- **Protocolo estadístico:** Verificación de normalidad multivariada (**Mardia / Henze-Zirkler** y gráfico Q-Q de **Distancias de Mahalanobis**), **PCA** estandarizado con gráfico de sedimentación y *Biplot* interpretado, y **MANOVA** con estadísticos **Lambda de Wilks (Λ)** y **Traza de Pillai**.

4. PLAN DE RECOPILACIÓN DE DATOS Y ANÁLISIS ÉTICO-LEGAL (ROBOTS.TXT Y TÉRMINOS)

Atributo	Fuente 1: Open-Meteo Archive & Forecast API	Fuente 2: SNIIM (Secretaría de Economía)
Endpoints / URLs	`https://archive-api.open-meteo.com/v1/archive` `https://api.open-meteo.com/v1/forecast`	`http://www.economia-sniim.gob.mx/nuevo/Consultas/MercadosNacionales/PreciosDeMercado/Agricolas/ConsultaFrutasYHortalizas.aspx`
Estructura y Formato	Respuesta nativa `JSON` columnar UTF-8 convertida a `CSV` con ficha criptográfica `.meta.json` (SHA-256).	Tablas estadísticas `HTML` procesadas con `BeautifulSoup4` y serie histórica consolidada en `CSV` + `.meta.json`.
Frecuencia y Automatización	Serie histórica de 60 meses descargada + **captura diaria automática en GitHub Actions** (`cron: "0 12 * * *"`).	Serie histórica de 60 meses en 4 mercados + monitoreo ético diario en `.github/workflows/captura-bronce.yml`.
Análisis de `robots.txt`	Archivado en `data/bronce/robots_txt/`. El subdominio API sirve `Disallow: /` para buscadores web (Googlebot), mientras que su portal autoriza llamadas API REST (documentado como Defecto #1 en PSP).	Archivado en `data/bronce/robots_txt/`. El servidor `economia-sniim.gob.mx/robots.txt` devuelve `HTTP 404` (sin restricciones de exclusión de robots).
Licencia y Términos de Uso	**Creative Commons Attribution 4.0 (CC BY 4.0)** para uso académico/no comercial (cuota: 10,000 req/día; el observatorio usa solo 4 req/día).	**Términos de Libre Uso de Datos Abiertos del Gobierno de México (MX-LibreUso)**, citando a la Secretaría de Economía / SNIIM.
Ética y Privacidad (LFPDPPP)	`User-Agent` institucional con correo de contacto, pausa obligatoria ≥ 1.5 s entre peticiones y **0 datos personales**.	`User-Agent` institucional, 1 sola petición de verificación por corrida (pausa ≥ 1.5 s) y **0 datos personales**.

5. EVIDENCIA DE LA MÁQUINA DE CAPTURA EN CAPA BRONCE Y SISTEMA PSP

5.1 Inventario Criptográfico Verificado en Capa Bronce (`data/bronce/`)

Archivo en Capa Bronce	Fuente	Registros	Periodos	Hash SHA-256 (`.meta.json`)
`open_meteo/agroclima_colima_diario_historico.csv`	Open-Meteo Archive API (ERA5-Land)	7,304	1,826 días	`a8e5f5c699898e47fbb50c3fc6af023519244d3e1f1a9879e0a64189ad0488cc`
`open_meteo/agroclima_colima_mensual_60m.csv`	Open-Meteo Archive API (Mensual)	240	**60 meses**	`6aad451dfcd2d2f033352a9a6182fac3800a818bc3b92fb2baa73cc7bd2ae240`
`sniim_limon/precios_limon_sniim_historico_60m.csv`	SNIIM - Secretaría de Economía	240	**60 meses**	`7dde14cf7f818a89294b73c91a15647315794c91ef7021c29fb276edd598adc2`
`open_meteo/captura_diaria_2026-11-09.csv`	Open-Meteo Forecast API (Diaria)	56	14 días	`61ecb7e0dbd0182a359cb23884d5d0ed415c00d77fb1f71966684cda47d02a5e`
`sniim_limon/monitoreo_sniim_2026-11-09.csv`	SNIIM Portal Frutas y Hortalizas	16	4 meses	`183b267f3a826005554f55a4840f9bbebea9a709baa175f1508bf43825ae51c6`

5.2 Tres Objetivos de Calidad Medibles (`calidad/objetivos.md`) y Registros PSP

- **Objetivo O1 (Disponibilidad y Fiabilidad Operativa):** Disponibilidad real `A = MTBF / (MTBF + MTTR) ≥ 95.0%` y tasa de éxito de captura diaria ≥ 95.0%, medida automáticamente desde `calidad/bitacora_capturas.jsonl` .
- **Objetivo O2 (Completitud e Integridad en Bronce):** Horizonte histórico ≥ 36 periodos (actualmente **60 meses = 166.7% del mínimo**), completitud ≥ 98.0% en variables críticas y **100% de coincidencia SHA-256**.
- **Objetivo O3 (Privacidad LFPDPPP y Cobertura de Pruebas): 0 datos personales** en Capa Bronce, **0 secretos expuestos** y cobertura de pruebas automatizadas ≥ 80% (actualmente **11/11 pruebas aprobadas en** `pytest`).

Archivo PSP en `calidad/`	Esquema Oficial Verificado	Resumen de Registros en E0
`calidad/tiempo-norberto.csv`	`fecha,inicio,fin,interrupcion_min,fase,actividad`	6 sesiones cronometradas cubriendo las fases de `planeacion` , `diseno` , `codigo` , `pruebas` y `revision` (595 min netos).
`calidad/defectos-norberto.csv`	`numero,fecha,tipo,fase_introducido,fase_eliminado,minutos_correccion,defecto_origen,descripcion`	4 defectos reales documentados y corregidos (tipos PSP: `interfaz` , `datos` , `funcion` , `verificacion` ; 57 min totales de corrección).
`calidad/bitacora_capturas.jsonl`	Eventos JSON Lines con `timestamp_utc` , `estado` , `duracion_seg` , `sha256`	Activa y actualizada automáticamente tanto en ejecución local como por `github-actions[bot]` en la nube.

6. FICHA DE ENTREGA E0 (MATRIZ DE TRAZABILIDAD PARA LOS DOCENTES)

Materia / Área	Criterio de la Rúbrica E0	Evidencia en el Repositorio (Tag `e0`)	Estado Verificado
Común (20 pts)	Pregunta concreta, entrevista de campo (≥ 15 min) y cliente con motivo de pago	`docs/E0/propuesta.md` (§1 y §2)	**CUMPLIDO (100%)** Entrevista de 22 min con 5 preguntas y aprendizajes.

Materia / Área	Criterio de la Rúbrica E0	Evidencia en el Repositorio (Tag `e0`)	Estado Verificado
Análisis Estadístico (20 pts)	Tres preguntas analíticas medibles (E1 pronóstico, E2 experimento 2^3, E3 MANOVA/PCA)	`docs/E0/propuesta.md` (§3.1, §3.2 y §3.3)	**CUMPLIDO (100%)** Variables, modelos y 4 grupos definidos.
Ingeniería de Datos (20 pts)	Plan de recopilación con estructura, formato, frecuencia, `robots.txt` y términos	`docs/fuentes/README.md`, `open_meteo.md`, `sniim_agro.md` y `data/bronce/robots_txt/`	**CUMPLIDO (100%)** Licencias CC BY 4.0 y Libre Uso MX + robots archivados.
Ingeniería de Datos (25 pts)	Dos fuentes funcionando, una en GitHub Actions y serie histórica ≥ 36 periodos en bronce	`extractores/`, `.github/workflows/captura-bronce.yml` y `data/bronce/` (60 meses)	**CUMPLIDO (100%)** 60 meses en ambas fuentes + GitHub Actions en verde.
Calidad / PSP (15 pts)	Registros individuales de defectos y tiempo, bitácora activa y 3 objetivos medibles	`calidad/tiempo-norberto.csv`, `defectos-norberto.csv`, `objetivos.md` y `bitacora_capturas.jsonl`	**CUMPLIDO (100%)** Validado con `pytest` y `pipeline.verificar_e0`.